

Pontificia Universidad Católica Madre y Maestra
Escuela de Ingeniería en Computación y Telecomunicaciones
ICC-321 Inteligencia de Negocios

Actividad 1 — Exploración de la fuente de datos

Práctica 1: Diseño e implementación de una solución de Inteligencia de Negocios

Estudiante: Enger Douglas

ID: 10144675

Profesora: Lisibonny Beato

Fecha: 26 de septiembre de 2026

1. Alcance y método de la exploración

Este documento corresponde a la **actividad 1 de la Práctica 1**: la exploración de la base de datos operacional que servirá de fuente para la solución de Inteligencia de Negocios. El objetivo es comprender las entidades y relaciones disponibles, la granularidad de cada tabla, las variables aprovechables para el análisis, los problemas de calidad presentes y las posibilidades analíticas que ofrece la fuente.

La base **BI_Practica_Retail** se creó ejecutando el script entregado con la práctica sobre **SQL Server 2022**. Todas las cifras de este documento provienen de consultas ejecutadas directamente sobre esa base; ninguna es estimada.


Observación sobre el script. El script original no se ejecuta tal cual: utiliza el alias de columna `LineNo` en el bloque que genera los detalles de orden, y `LINENO` es palabra reservada de Transact-SQL, por lo que el motor devuelve el error «Incorrect syntax near the keyword LineNo». Se renombró ese alias a `LineaNo` (9 ocurrencias) y con ese cambio el script corre completo.

2. Principales entidades y relaciones

La fuente contiene **10 tablas** en el esquema `dbo`, con 9 claves foráneas declaradas. Se distinguen dos grupos: las tablas de **catálogo** (describen el negocio y cambian poco) y las tablas **transaccionales** (registran los hechos y crecen con la operación).

Tabla	Tipo	Filas	Contenido
Categoria	Catálogo	10	Categorías comerciales de producto.
Proveedor	Catálogo	24	Proveedores, con país y fecha de alta.
Producto	Catálogo	250	SKU, nombre, marca, costo unitario, precio de lista y estado (activo o no).
Tienda	Catálogo	12	Sucursales, con ciudad, provincia, tipo y fecha de apertura.
Cliente	Catálogo	2 500	Datos demográficos, ubicación, segmento y fecha de registro.
Promocion	Catálogo	15	Campañas con vigencia, porcentaje de descuento y canal.
OrdenVenta	Transaccional	30 000	Cabecera de la venta: fecha y hora, tienda, cliente, canal, estado y promoción.
DetalleOrden	Transaccional	76 784	Línea de la venta: producto, cantidad, precio unitario y descuento.
Pago	Transaccional	28 803	Pago de la orden: fecha, método y monto.
Devolucion	Transaccional	5 139	Devolución de una línea: fecha, cantidad devuelta, motivo y reembolso.

El diagrama siguiente resume las relaciones declaradas en la base:



- Una **orden** pertenece a una tienda, opcionalmente a un cliente y opcionalmente a una promoción.
- Una **orden** tiene entre 1 y 4 líneas de detalle, y cada línea apunta a un producto.
- Un **producto** pertenece a una categoría y a un proveedor.
- Un **pago** corresponde a una orden completa; una **devolución**, a una línea de detalle.

3. Naturaleza y granularidad de los datos

Identificar el grano de cada tabla es el paso decisivo de esta exploración, porque de él depende el diseño del modelo dimensional. Los conteos confirman lo siguiente:

Tabla	Grano (una fila representa...)	Comprobación realizada
OrdenVenta	una venta registrada, con fecha y hora	30 000 filas, 30 000 OrdenID distintos
DetalleOrden	un producto dentro de una orden	76 784 filas sobre 30 000 órdenes: 2,56 líneas por orden en promedio
Pago	el pago de una orden completa	28 803 pagos para 28 803 órdenes distintas: un pago por orden
Devolucion	la devolución de una línea de detalle	5 139 filas con 5 139 DetalleOrdenID distintos
Cliente / Producto / Tienda / Promocion / Categoria / Proveedor	una entidad del catálogo	Clave primaria simple de tipo IDENTITY en todas

Distribución de líneas por orden:

Líneas en la orden	1	2	3	4
Órdenes	6 099	8 009	8 901	6 991

Implicación para el modelo dimensional. Pago y Devolucion **no están al mismo grano** que DetalleOrden. Incorporar el método o el monto de pago en un hecho de ventas a nivel de línea duplicaría los montos tantas veces como líneas tenga la orden. El pago debe tratarse a nivel de orden y las devoluciones como un hecho aparte, a nivel de línea.

4. Variables disponibles para el análisis

Las columnas de la fuente se clasifican según el papel que pueden cumplir en el modelo dimensional:

Papel	Variables
Métricas (hechos)	Cantidad, PrecioUnitario y DescuentoMonto en DetalleOrden; CostoUnitario y PrecioLista en Producto; Monto en Pago; CantidadDevuelta y MontoReembolso en Devolucion.
Atributos de tiempo	FechaOrden (con hora), FechaPago, FechaDevolucion, FechaRegistro del cliente, FechaApertura de la tienda, FechaLanzamiento del producto, vigencia de las promociones.
Atributos de producto	SKU, NombreProducto, Marca (12 marcas), Categoria (10 categorías), Proveedor (24) y País del proveedor, Activo.
Atributos de cliente	Sexo, FechaNacimiento, Ciudad, Provincia (8), Segmento (Regular, Preferente, Corporativo).
Atributos de tienda	NombreTienda, Ciudad, Provincia, TipoTienda (Calle, Centro comercial, Express, Outlet).
Atributos de la venta	CanalVenta (Tienda, Web, App), EstadoOrden, MetodoPago, PromocionID y porcentaje de descuento, Motivo de devolución.

Algunas distribuciones relevantes observadas:

Variable	Distribución observada
CanalVenta	Tienda 15 223 órdenes (50,7 %) · Web 8 252 (27,5 %) · App 6 525 (21,8 %)
EstadoOrden	Completada 28 803 (96,01 %) · Cancelada 1 197 (3,99 %)
Segmento de cliente	Regular 1 553 · Preferente 643 · Corporativo 304
TipoTienda	Calle 4 · Centro comercial 4 · Express 3 · Outlet 1
MetodoPago	Los cinco métodos se reparten de forma casi uniforme (entre 5 755 y 5 766 pagos cada uno)
Promoción	Solo 5 966 órdenes (19,9 %) se asocian a una promoción; los descuentos van de 10 % a 20 %
Cobertura temporal	Del 1 de enero de 2023 al 15 de agosto de 2026, con órdenes en las 24 horas del día

5. Problemas de calidad de datos detectados

La exploración identificó seis situaciones que deben resolverse en el proceso ETL antes de cargar el Data Warehouse. La columna «magnitud» indica el volumen real medido en la base.

#	Hallazgo	Magnitud	Tratamiento propuesto en el ETL
1	Órdenes sin cliente identificado (ClientelD nulo)	2 407 órdenes (8,02 %)	No se pueden descartar: son ventas reales. Se asignan a un miembro «No identificado» en la dimensión Cliente.
2	Cientes sin sexo registrado	254 de 2 500 (10,2 %)	Sustituir el nulo por la categoría «No especificado», para no perder al cliente en los análisis demográficos.
3	Órdenes canceladas con líneas de detalle	1 197 órdenes · 3 117 líneas · RD\$ 12,1 millones	Excluirlas del hecho de ventas. Si se incluyen, inflan los ingresos casi un 4 %.
4	Órdenes sin promoción asociada	24 034 órdenes (80,1 %)	Es un nulo legítimo. Se resuelve con un miembro «Sin promoción» en la dimensión Promoción.
5	Líneas que venden productos marcados como inactivos	3 123 líneas sobre 10 productos inactivos	Conservarlas: son ventas históricas válidas. El atributo Activo se guarda en la dimensión Producto.
6	Ventas y devoluciones en tablas de distinto grano	28 803 pagos (grano orden) frente a 76 784 líneas	Separar los hechos por grano, según lo indicado en la sección 3.

También se verificaron condiciones que **no** presentan problemas, lo que simplifica el ETL:

- No hay devoluciones con cantidad mayor a la vendida, ni anteriores a la fecha de la orden, ni asociadas a órdenes canceladas.
- No hay pagos de órdenes canceladas; el monto de cada pago coincide exactamente con el neto de su orden en las 28 803 órdenes pagadas.
- No hay productos con precio de lista inferior al costo, ni claves foráneas huérfanas.

6. Posibilidades de análisis que ofrece la fuente

Con las variables disponibles, la fuente permite responder preguntas de negocio en cinco frentes. Los valores siguientes, calculados sobre las órdenes completadas, muestran que los datos tienen suficiente variabilidad para sostener el análisis:

Indicador (órdenes completadas, 2023–2026)	Valor
Unidades vendidas	210 229
Venta bruta	RD\$ 298 749 966
Descuentos otorgados	RD\$ 9 758 409
Venta neta	RD\$ 288 991 558
Costo de la mercancía vendida	RD\$ 213 382 973
Margen bruto	RD\$ 75 608 585 (26,2 %)

Frentes de análisis identificados

Frente	Preguntas que la fuente permite responder
Rentabilidad	¿Qué categorías, marcas o proveedores aportan más margen y no solo más ingresos? Papelería es la categoría de mayor venta neta (RD\$ 38,7 millones) pero su margen es el más bajo del grupo líder (23,3 %), mientras Cuidado personal rinde 27,9 %.
Devoluciones	¿Qué productos y categorías concentran las devoluciones? La tasa media es de 6,7 % de las líneas, pero Moda llega a 13,4 % y Electrodomésticos a 9,6 %. Los motivos se reparten de forma pareja entre cinco causas.
Canal y tienda	¿Cómo se comparan tienda física, Web y App en ticket promedio y margen? ¿Qué tipo de tienda rinde mejor por sucursal?
Promociones	¿Las órdenes con promoción generan más volumen del que sacrifican en descuento? Solo una de cada cinco órdenes usa promoción, lo que permite comparar contra un grupo de control amplio.
Cliente	¿Cómo se comportan los segmentos Regular, Preferente y Corporativo? ¿Qué provincias concentran la venta? Debe considerarse que el 8 % de las ventas no tiene cliente asociado.

7. Conclusiones de la exploración

- La fuente es adecuada para una solución de BI: cubre **44 meses** de operación, 30 000 órdenes y 76 784 líneas, con dimensiones suficientes (producto, cliente, tienda, promoción, canal y tiempo).
- El proceso de negocio natural para el modelo es la **venta al detalle**, y el grano candidato es la **línea de detalle de una orden completada**, que es el nivel más fino disponible y permite agregar hacia arriba sin pérdida.
- Las devoluciones justifican una **segunda tabla de hechos** al mismo grano de línea, en lugar de forzarse dentro del hecho de ventas.
- El pago debe analizarse a nivel de orden; llevarlo a la línea rompería la aditividad de los montos.
- Los seis problemas de calidad detectados son tratables en el ETL y ninguno obliga a descartar datos, salvo las órdenes canceladas, que deben excluirse del hecho de ventas.

Con estos elementos queda preparada la **actividad 2** (definición del problema de toma de decisiones) y la **actividad 3** (diseño del modelo dimensional).